

多Agent协同-8-基于LangGraph的多级意图识别 异常兜底与周期性自动化测试评估系统工单

V1.0-20260810

多Agent 协同项目

编排、意图与自动化测试系统任务工单

1 基本信息

2 任务描述

一、任务描述

1 背景介绍

2 首次工单推荐实现方案（最小可上线MVP）

二、阶段开发任务

任务一：图谱Schema 设计与强制修改决策（0.5 人日）

1.1 三方对齐机制（Human + AI-A + AI-B）

1.2 对齐决策与方法论

1.3 落地提示词模板：

任务二：图谱记忆平台与状态干预模块开发（1 人日）—— Loop Engineering 自驱实现

2.1 开发方法论（Loop Engineering 闭环机制）：

2.2 Loop 驱动提示词：

2.3 自动化测试要求：

任务三：运行自动化测试集与ROI 评估对比（1 人日）

3.1 测试方法论：

3.2 对抗压测提示词：

任务四：异常退出审计与面试QA 沉淀（0.5 人日）

4.1 审计与修复方法：

4.2 面试答辩演练提示词：

工时预估

产出物

备注

多Agent 协同项目

编排、意图与自动化测试系统任务工单

八维文化与产业研究院

2026 年8 月

1 基本信息

项目	内容
工单对应的项目名称	多Agent 协同项目
工单编号	人工智能NLP-多Agent 协同-编排、意图与自动化测试系统任务工单
工单类型	AI 协作工单
创建时间	2026 年8 月10 日
创建人	王洪荣

2 任务描述

一、任务描述

1 背景介绍

前序系统痛点承接：在多Agent-3（餐饮分析系统）的多级决策中，意图识别在面对口语化输入时极易失误。多Agent-5（评测系统）缺乏对于复杂逻辑流转的端到端自动化测试体系。

业务场景具体问题举例：在医疗健康在线问诊的真实场景中，患者突然发送了一条具有强烈情绪的口语化信息："我肚子现在疼得要死，腰都直不起来，下面在流血，是不是要生了啊？" 由于用户的表述具有极高的多样性和情绪伪装，旧系统的大模型意图识别器（Intent Classifier）发生了严重的幻觉，将其分

类为了"普通产前焦虑（妇科门诊）"而没有触发急诊预警。不仅如此，当大模型由于网络抖动或Token 上限溢出，返回了格式损坏的非标准JSON 指令时（如"{intent: 'emergency'... [truncated]}"），由于系统缺乏对Output Parse 失败的兜底防御机制，下游工作流直接抛出Python 异常崩溃，导致整个问诊通道阻断。此外，由于系统缺乏周期性的自动化评测方案，开发人员在每次微调提示词或升级模型后，必须由测试团队手动测试上百个测试用例，无法及时发现"修复了重症意图，却导致普通感冒意图识别率下降20%"的模型能力退化（Regressive Failure）问题。

重构需求：使用LangGraph 框架从0 编排一个智能对话流。该工作流能通过"静态规则/轻量模型过滤+ LLM"双层节点实现多级意图识别。同时，为解决该智能体在长期运行中缺乏自动化评测的问题，从零构建一套自动化周期性测试方案，自动评估智能体运行的稳定性、幻觉率与关键指标召回率。

2 首次工单推荐实现方案（最小可上线MVP）

- LangGraph 工作流编排：设计Node A 为确定性静态意图识别与过滤节点（基于关键词正则树/极轻量分类模型），Node B 为大模型逻辑意图识别节点。
- 自动化测试调度引擎：编写自动化测试框架，支持自动化生成测试样本、周期性调度（如每天凌晨）、并输出评估指标报告（TTFT、Token 消耗量、召回率）。

二、阶段开发任务

任务一：图谱Schema 设计与强制修改决策（0.5 人日）

1.1 三方对齐机制（Human + AI-A + AI-B）

在编写任何业务代码前，必须进行三方对齐。引入两个不同类型的AI 模型（如AI-A：逻辑分析型助手 Gemini，AI-B：工程实现型助手Cursor/Claude Code），与**人类（学生）**共同组成评审小组，消除认知偏差与安全盲区。

1.2 对齐决策与方法论

- 采用分层状态机（Hierarchical State Machine）编排智能体流向。
- 定义Node A（正则树/TF-IDF 静态过滤）与Node B（LLM 意图判定）的分流拦截边界。
- 设计周期性自动化测试的断言基准（如意图召回率Recall 目标≥90%，幻觉率≤2%）。

1.3 落地提示词模板：

请设计基于LangGraph 的双层意图识别工作流方案。

1. 规范Node A 静态过滤器的匹配逻辑（通过Trie 树过滤基础医疗常识关键词）。

2. 规范Node B 的System Prompt 与JsonOutputParser。
3. 提供一套自动化测试用例数据格式（CSV/JSON），包含输入、预期意图类别、预期路由Node。

任务二：图谱记忆平台与状态干预模块开发（1 人日）—— Loop Engineering 自驱实现

2.1 开发方法论（Loop Engineering 闭环机制）：

步骤1：创建自动化评测测试tests/test_eval_pipeline.py，预置30 个包含复杂医疗表述的输入。

步骤2：编写LangGraph 编排代码，实现双层过滤节点。

2.2 Loop 驱动提示词：

【目标】：在graph/workflow.py 中编写LangGraph 编排流，在eval/runner.py 中编写自动化测试执行框架。

【Loop 执行规则】：

1. 读取tests/test_eval_pipeline.py。
2. 编写workflow.py 的节点路由逻辑与Fallback 重试逻辑（处理LLM 吐出损坏JSON 的情况）。
3. 编写runner.py 以便能一键启动并自动计算Recall 指标。
4. 运行 `pytest tests/test_eval_pipeline.py`。
5. 捕获意图识别失败、JSON 解析异常或路由死循环等报错，自动调整Prompt 与Fallback 代码，直到30 个测试用例全部跑通。

2.3 自动化测试要求：

测试必须覆盖test_json_parse_fallback（模拟LLM 截断返回损坏的JSON，断言Fallback 节点能成功修复并返回默认紧急路由）和test_eval_runner_metric（断言评测结果字典中包含Recall 和TTFT）。

任务三：运行自动化测试集与ROI 评估对比（1 人日）

3.1 测试方法论：

- 采用A/B 性能对比测试（A/B Benchmark Testing）。
- 对比"纯LLM 路由"与"静态规则+ LLM 双层路由"在时延和Token 消耗上的差异。

3.2 对抗压测提示词：

编写脚本scripts/run_ab_benchmark.py，分别使用"纯LLM"与"双层混合流"运行100 条复杂意图测试集。

- 1. 记录各自的API Token 消耗、平均响应时间（TTFT）、意图分类准确率。
- 2. 自动生成优化前后数据对比Markdown 表格，并计算出双层过滤方案降低了多少运行成本。

任务四：异常退出审计与面试QA 沉淀（0.5 人日）

4.1 审计与修复方法：

- 执行鲁棒性与兜底机制审计（Robustness & Fallback Audit）。
- 检查如果大模型API 遭遇网络故障或拒绝响应时，工作流是否会由于捕获异常失败而直接挂起或退出。强制引入超时重试（Retry with Exponential Backoff）和死信队列（Dead Letter Queue）。

4.2 面试答辩演练提示词：

请根据本次工单的实现，针对以下两个面试问题，生成我的自述答辩话术，突出我对意图兜底设计和周期性测试体系从零构建的能力：

- 1. 在医疗健康（或特定领域）对话场景下，意图识别的具体实现方案是什么？此外，面对用户表述多样性及大模型幻觉风险，如何平衡规则编写与大模型能力以做好兜底？
- 2. 假设开发人员已排好一个智能体，在缺乏现成测试体系、标准和流程的情况下，你会如何设计一套相对自动化的周期性测试方案？请详细描述前置路径、构建体系及最终提供的测试报告。

工时预估

3 人日

产出物

阶段	交付成果物名称	验收标准
任务一	1. 《双层意图识别与自动化测试方案设计说明书》 2. 《三方需求互评与测试策略记录》	标准红线：明确给出自动化测试的前置路径设计、测试断言基准。
任务二	1. LangGraph 意图识别流源码 2. 周期性自动化测试框架源码	功能标准：测试框架支持一键定时触发，能够自动抓取Agent 执行日志并记录异常。

任务三	1. 自动化测试样本集 (≥ 100 个) 2. 《AI 智能体周期性自动化测试报告》	指标红线：自动化运行覆盖率达100%；相对于纯LLM，混合意图流的Token 消耗降低40%。
任务四	1. 《AI 代码输出异常兜底机制审计报告》 2. 《智能体编排与周期性测试面试QA 知识库》	答辩标准：必须流畅且全面地回答上述意图识别兜底及自动化测试框架设计的面试问题。

备注